

Plantilla del Estado del Arte

Author (s): Gutiérrez Idrobo, D., Vejarano Sánchez L., Realpe Grijalba, E., Varona Taborda M.

Title of paper: College student mental health assessment: Predictive models based on machine learning and feature importance analysis

Journal: "Molecular & Cellular Biomechanics"

Volume (issue): Vol. 22, N.º 3

pag – pag (year): 237 – 248 (2020)

Escriba con sus propias palabras

Estado del arte que hace el autor

(1 página)

Los autores presentan una solución basada en técnicas avanzadas de Machine Learning (ML) orientada a la evaluación y predicción de la salud mental de estudiantes universitarios utilizando el cuestionario SCL-90. El estudio surge ante la creciente preocupación por los problemas de salud mental en la población estudiantil universitaria, agravados por factores como la presión académica, las expectativas familiares y la transición al entorno universitario. Los métodos tradicionales de evaluación psicológica, aunque válidos, son subjetivos, consumen mucho tiempo y tienen limitaciones para la detección temprana y la intervención a gran escala.

El trabajo se enmarca dentro de investigaciones previas que exploran la aplicación de la inteligencia artificial y el aprendizaje automático en el ámbito de la salud mental, particularmente para la detección de condiciones como depresión y ansiedad. A diferencia de enfoques que se centran únicamente en la precisión predictiva, los autores integran técnicas para abordar desafíos específicos como el desbalance de clases en los datos (usando SMOTE), la optimización de hiperparámetros (con el algoritmo NGO) y, de manera crucial, la interpretabilidad del modelo (mediante SHAP). Esto les permite no solo predecir, sino también explicar qué factores psicológicos son más determinantes.

En el contexto del estado del arte, el artículo se apoya en estudios que han demostrado la superioridad de los modelos basados en árboles y ensambles (como Random Forest o XGBoost) sobre los métodos lineales para tareas de clasificación complejas. Asimismo, retoma y aplica metodologías modernas de optimización bioinspirada y explicabilidad de modelos de caja negra, contribuyendo a una línea de investigación que busca hacer que los sistemas de IA en salud sean más transparentes y confiables.

En este sentido, el trabajo contribuye significativamente a la investigación en salud mental digital, al demostrar de manera práctica y con una muestra grande (11,943 estudiantes) cómo un flujo de trabajo integral de ML puede lograr una precisión excepcional (99.8% con LGB) y, al mismo tiempo, generar conocimientos accionables sobre los síntomas más predictivos, como los obsesivo-compulsivos y la ansiedad.

Motivación del autor (críticas del autor a otros trabajos)

(0.5 página)

La motivación principal del estudio radica en las limitaciones identificadas en los enfoques tradicionales de evaluación de salud mental y en las implementaciones previas de modelos de Machine Learning. Los autores señalan que, aunque existen estudios que aplican ML a la salud mental, muchos presentan deficiencias clave.

En primer lugar, critican que muchos trabajos previos no abordan adecuadamente el problema del desbalance de clases, común en datos de salud mental donde la mayoría de los individuos están sanos. Esto lleva a modelos sesgados que tienen alta precisión general pero un rendimiento pobre en la identificación de los casos positivos (bajo recall), que son los clínicamente más importantes.

En segundo lugar, los autores destacan que la mayoría de las investigaciones se centran únicamente en la precisión predictiva, descuidando la interpretabilidad del modelo. Esto genera un problema de "caja negra", donde no es claro por qué el modelo toma ciertas decisiones, lo que limita su utilidad clínica y la confianza de los profesionales de la salud.

Finalmente, señalan que los métodos convencionales de optimización de hiperparámetros, como la búsqueda en cuadrícula (grid search) o aleatoria (random search), son computacionalmente costosos y pueden no encontrar la configuración óptima de manera eficiente.

Frente a estas limitaciones, los autores justifican su propuesta integrada: un modelo de alto rendimiento (LGB) optimizado con un algoritmo bioinspirado eficiente (NGO), equilibrado con SMOTE e interpretado con SHAP. Su objetivo es superar estas críticas, ofreciendo una herramienta que sea a la vez precisa, robusta frente al desbalance, eficiente y, sobre todo, explicable.

Descripción del aporte del autor

(2 páginas)

El principal aporte de este artículo es el diseño, implementación y evaluación exhaustiva de un pipeline integral de Machine Learning para la evaluación y predicción de la salud mental de estudiantes universitarios. Este aporte no es solo un modelo predictivo, sino un marco metodológico que combina técnicas de vanguardia para abordar los principales desafíos en la aplicación de IA a datos de salud mental.

El problema central identificado es la necesidad de un sistema de evaluación que sea: 1) Objetivo y escalable, superando las limitaciones de tiempo y subjetividad de las entrevistas clínicas tradicionales; 2) Preciso en la identificación de estudiantes en riesgo, especialmente frente a datos desbalanceados; 3) Interpretable, para que sus predicciones sean confiables y útiles para guiar intervenciones.

El aporte del estudio se materializa en los siguientes componentes clave:

1. **Recolección y Procesamiento de Datos a Gran Escala:** Se recopilieron datos de 11,943 estudiantes usando el cuestionario SCL-90 validado, asegurando una base sólida para el análisis.
2. **Arquitectura de Modelado Avanzada:** Se entrenaron y compararon sistemáticamente nueve algoritmos de ML diferentes (RF, LDA, QDA, KNN, DT, XGB, LGB, SVC, MLP), identificando al Light Gradient Boosting (LGB) como el más eficaz.
3. **Solución al Desbalance de Clases:** La implementación de la técnica SMOTE permitió generar muestras sintéticas de la clase minoritaria (estudiantes con problemas de salud mental), mejorando drásticamente la capacidad de los modelos para detectar casos positivos (aumentando el recall de modelos como LDA del 92.3% al 97.8%).
4. **Optimización Eficiente de Hiperparámetros:** En lugar de métodos tradicionales, se utilizó el algoritmo bioinspirado Northern Goshawk Optimization (NGO) para encontrar la combinación óptima de parámetros para cada modelo de manera más eficiente, mejorando su rendimiento.
5. **Modelo Explicable y con Capacidad de Insight Clínico:** La aplicación del análisis SHAP transforma el modelo predictivo de "caja negra" en una herramienta explicable. Este es quizás el aporte más significativo, ya que permite:
 - a. **Identificar los síntomas más influyentes:** Revela que los síntomas obsesivo-compulsivos y de ansiedad son los predictores más importantes del estado de salud mental en la población estudiada.
 - b. **Entender el impacto de cada factor:** Muestra cómo cambios en la severidad de cada síntoma afectan la predicción del modelo (valores SHAP).
 - c. **Ofrecer explicaciones individuales:** Permite entender por qué el modelo clasificó a un estudiante específico como en riesgo (ver Figura 8 del artículo).
6. **Validación Rigurosa:** El uso de Validación Cruzada de 5 pliegues (K-fold) garantiza una evaluación robusta y generalizable del rendimiento del modelo, minimizando el riesgo de sobreajuste (overfitting).

Este enfoque integral permite a administradores universitarios, consejeros y profesionales de la salud contar no solo con una herramienta de detección temprana de alta precisión, sino también con

conocimiento accionable sobre qué dimensiones psicológicas priorizar en programas de intervención y prevención, personalizando así el apoyo a los estudiantes.

Proceso para obtener el aporte que considera el autor

(1. página)

Para obtener el aporte propuesto, los autores siguieron un flujo de trabajo metodológico sistemático y bien definido, dividido en etapas secuenciales:

1. Definición del Problema y Objetivos: Se estableció el objetivo de predecir el estado de salud mental (clasificación binaria: con problemas / sin problemas) a partir de las puntuaciones del SCL-90.
2. Recolección y Preprocesamiento de Datos:
 - a. Se distribuyó el cuestionario SCL-90 en línea a estudiantes universitarios.
 - b. Se limpiaron los datos, eliminando encuestas incompletas (<95% de respuestas) e imputando valores faltantes menores al 10%.
 - c. Se calcularon las puntuaciones promedio para cada una de las 9 dimensiones del SCL-90 (somatización, obsesivo-compulsivo, etc.) para cada estudiante.
3. Análisis Exploratorio de Datos (EDA):
 - a. Se analizó la distribución de las puntuaciones para cada síntoma (Figura 2).
 - b. Se calcularon matrices de correlación para entender las relaciones entre las diferentes dimensiones psicológicas (Figura 3).
4. Preparación del Conjunto de Datos para Modelado:
 - a. Balanceo: Se aplicó la técnica SMOTE al conjunto de entrenamiento para generar muestras sintéticas de la clase minoritaria y equilibrar las clases.
 - b. División: Se utilizó Validación Cruzada de 5 pliegues (K-fold) para dividir los datos de manera iterativa en conjuntos de entrenamiento y prueba, asegurando una evaluación robusta.
5. Modelado y Optimización:
 - a. Se seleccionaron nueve algoritmos de clasificación para su comparación.
 - b. Para cada algoritmo, se utilizó el algoritmo NGO para buscar de manera eficiente la combinación óptima de hiperparámetros dentro de un espacio predefinido (ver Tabla 2).
 - c. Los modelos se entrenaron con los datos balanceados (con SMOTE) y los hiperparámetros optimizados.
6. Evaluación y Selección del Modelo:
 - a. Se evaluó el rendimiento de cada modelo en el conjunto de prueba usando métricas clave: Precisión (Accuracy), Exhaustividad (Recall) y Puntuación F1.
 - b. Se generaron Matrices de Confusión (Figura 4) y Curvas ROC (Figura 5) para un análisis detallado del rendimiento.
 - c. Se seleccionó el modelo Light Gradient Boosting (LGB) como el de mejor rendimiento global.
7. Interpretación del Modelo (Aporte Clave):
 - a. Sobre el modelo LGB seleccionado, se aplicó el marco SHAP.
 - b. Se generaron gráficos de importancia global de características (Figura 7) y gráficos de dependencia (Figura 6) para entender el impacto de cada síntoma.
 - c. Se crearon explicaciones locales para predicciones individuales (Figura 8), demostrando la transparencia del modelo.

Este proceso estructurado, que va desde los datos crudos hasta la interpretación clínica, es fundamental para garantizar la validez, confiabilidad y utilidad práctica del aporte final.

Proceso para resolver el problema considerado por el autor

(1. página)

El problema central (evaluar y predecir la salud mental de manera objetiva, precisa e interpretable) se

resolvió mediante la implementación y validación del pipeline de Machine Learning descrito anteriormente sobre los datos reales de 11,943 estudiantes.

La solución se aplicó de la siguiente manera concreta:

1. Ejecución del Modelo Optimizado: Una vez identificado el LGB como el mejor algoritmo y optimizados sus hiperparámetros con NGO, el modelo final se entrenó con todos los datos de entrenamiento preparados (balanceados con SMOTE).
2. Generación de Predicciones: El modelo LGB entrenado se utilizó para predecir el estado de salud mental en el conjunto de prueba independiente (2,388 muestras), que no había sido visto durante el entrenamiento.
3. Validación de los Resultados: El rendimiento se cuantificó de manera objetiva:
 - a. El modelo LGB logró una precisión (accuracy) del 99.80%, cometiendo solo 6 clasificaciones erróneas de 2,388.
 - b. La exhaustividad (recall) fue del 99.83%, demostrando una capacidad excelente para identificar a casi todos los estudiantes que realmente tenían problemas de salud mental.
 - c. El área bajo la curva ROC (AUC) fue de 1.000, indicando una capacidad de discriminación perfecta entre las clases en este conjunto de prueba.
4. Extracción de Conocimiento y Explicación: Más allá de las métricas, el proceso de resolución incluyó el análisis SHAP para traducir las predicciones numéricas en conocimiento clínico útil:
 - a. Se confirmó que los síntomas obsesivo-compulsivos y de ansiedad eran los principales impulsores de las predicciones del modelo.
 - b. Se observó que el nivel de grado (año de estudio) era un factor demográfico importante, siendo los estudiantes de primer año los menos propensos a ser clasificados con problemas.
 - c. Se pudo explicar caso por caso por qué un estudiante recibió una determinada clasificación, señalando qué síntomas contribuyeron positiva o negativamente a esa decisión.

Por lo tanto, el problema no solo se resolvió con un modelo de alta precisión, sino que la solución misma se convirtió en una herramienta de diagnóstico auxiliar que proporciona razones para sus conclusiones, cumpliendo así el objetivo de ser una herramienta tanto predictiva como explicativa para apoyar la toma de decisiones en salud mental universitaria.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros) (0.5 página)

Las métricas utilizadas incluyen:

- Precisión (Accuracy): Proporción total de predicciones correctas.
- Exhaustividad (Recall o Sensibilidad): Proporción de casos positivos reales que fueron correctamente identificados. Crítica en salud, donde no pasar por alto un caso es prioritario.
- Puntuación F1 (*F1-Score*): Media armónica entre la Precisión y la Exhaustividad, balanceando ambas preocupaciones.
- Curva ROC y AUC: Evalúa la capacidad del modelo para distinguir entre clases en todos los umbrales de decisión posibles.

Resultados obtenidos y comparación:

- El modelo Light Gradient Boosting (LGB) optimizado obtuvo resultados excepcionales:
- Precisión: 99.80%
- Exhaustividad: 99.83%
- F1-Score: 99.80%
- AUC: 1.000

Los autores comparan sus resultados con estudios previos para respaldar su aporte:

- Vaishnavi et al. (2022) utilizó una técnica de stacking y reportó una precisión del 81.75%.

- Cheng & Haw (2023) usó Random Forest y logró una precisión del 83.23%.

El modelo LGB de este estudio (99.80%) supera significativamente estos antecedentes, con una mejora de más de 16 puntos porcentuales. Esta superioridad se atribuye a la combinación sinérgica de:

1. El uso de un algoritmo de ensamble avanzado (LGB) eficiente para grandes volúmenes de datos.
2. La optimización inteligente de hiperparámetros con NGO (en lugar de búsqueda aleatoria o en cuadrícula).
3. El manejo explícito del desbalance de clases con SMOTE, que mejora especialmente la exhaustividad.

Matriz

(0.5 página)

Variable Dependiente

Variable	Dimensiones	Indicadores	Instrumentos
Estado de salud mental del estudiante universitario (Dependiente)	Estado psicológico	Nivel de ansiedad	Cuestionario psicológico
		Nivel de depresión	Escala de depresión
		Nivel de estrés	Escala de estrés académico
	Clasificación	Estado mental (normal / en riesgo / crítico)	Modelo predictivo
	Resultado del modelo	Predicción del estado mental	Algoritmos de Machine Learning (Random Forest)

Variable Independiente

Variable independiente	Dimensiones	Indicadores	Instrumentos
Factores académicos	Rendimiento académico	Promedio académico	Registro académico
		Cursos desaprobados	Sistema institucional

	Progreso académico	Ciclo académico	Base de datos universitaria
Factores psicológicos	Salud emocional	Nivel de ansiedad	Cuestionario psicológico
		Nivel de depresión	Escala psicológica
		Nivel de estrés	Encuesta académica
Factores conductuales	Comportamiento estudiantil	Hábitos de estudio	Encuesta
		Horas de estudio	Registro/autorreporte
Factores sociodemográficos	Datos personales	Edad	Ficha del estudiante
		Sexo	Registro institucional
	Formación	Carrera profesional	Base de datos académica