

Plantilla del Estado del Arte

Author (s): Luo, L.

Title of paper: Research on practical education model of mental health development of college students in higher education institutions in the context of big data

Journal: "Applied Mathematics and Nonlinear Sciences"

Volume (issue): Vol. 9, No. 1

pag – pag (year): 1-14 (2024)

Escriba con sus propias palabras

Estado del arte que hace el autor

(1 página)

Los autores presentan un modelo innovador de monitoreo y educación en salud mental para estudiantes universitarios, aprovechando las oportunidades que ofrece la era del Big Data. El estudio se centra específicamente en estudiantes de instituciones de educación superior y propone un sistema que utiliza datos comportamentales pasivos (consumo, control de acceso, navegación web y calificaciones históricas) para identificar problemas de salud mental de manera objetiva y temprana. El trabajo surge ante la necesidad de superar las limitaciones de los métodos tradicionales de evaluación psicológica, que suelen ser subjetivos, reactivos (solo cuando el estudiante busca ayuda) y difíciles de escalar.

El trabajo se enmarca dentro de una línea de investigación emergente que busca aplicar técnicas de ciencia de datos e inteligencia artificial al bienestar estudiantil. A diferencia de enfoques anteriores que se basaban principalmente en cuestionarios autoaplicados o intervenciones grupales, este estudio propone un método proactivo y basado en evidencias digitales. Se apoya en investigaciones previas que han identificado correlaciones entre comportamientos observables (patrones de sueño, alimentación, sociabilidad) y salud mental, pero lleva este concepto a un nivel operativo mediante la extracción automatizada de características y la construcción de un modelo predictivo.

En el contexto del estado del arte, el artículo reconoce contribuciones previas en el uso de análisis de árboles de eventos, consejería grupal, modelos SPOC y reconocimiento inteligente para la educación en salud mental. Sin embargo, critica que muchos de estos enfoques no aprovechan plenamente el vasto volumen de datos digitales que las instituciones educativas ya recopilan. Su principal contribución radica en integrar un pipeline de procesamiento de datos completo: desde la recolección y preprocesamiento de datos heterogéneos, pasando por la extracción de características profundas con Redes Neuronales Convolucionales (CNN), hasta la clasificación final con un modelo de Random Forest (RF). Este enfoque híbrido (CNN + RF) para analizar datos comportamentales secuenciales y tabulares representa

una propuesta técnica distintiva dentro del campo.

Motivación del autor (críticas del autor a otros trabajos)

(0.5 página)

La motivación principal del estudio surge de identificar una brecha significativa entre el potencial de los datos disponibles en las universidades digitales y su uso efectivo para la promoción de la salud mental. Los autores critican que, a pesar de que las instituciones de educación superior han implementado diversos sistemas de gestión (tarjetas universitarias, control de acceso, plataformas de aprendizaje), la información generada por estos sistemas no se utiliza de manera integrada ni con fines de bienestar estudiantil.

En segundo lugar, señalan que muchos de los modelos educativos y de intervención en salud mental revisados en la literatura son genéricos o reactivos. Por ejemplo, métodos como la consejería grupal o los cursos SPOC dependen de que el estudiante participe activamente o identifique su propio problema. Frente a esto, los autores proponen un sistema proactivo y de detección temprana que pueda identificar señales de riesgo a partir del comportamiento diario, incluso antes de que el estudiante o un profesor perciba un problema.

Finalmente, aunque reconocen investigaciones previas que utilizan modelos inteligentes para la salud mental, los autores sugieren que muchas no abordan adecuadamente la complejidad y multimodalidad de los datos comportamentales. Datos como los registros web (secuenciales y de alta dimensión) requieren técnicas sofisticadas de extracción de características. Su trabajo justifica el uso de una CNN para este propósito, argumentando que supera métodos más simples y captura patrones temporales y contextuales más profundos en el comportamiento en línea, que luego se combinan con características estructuradas (consumo, notas) en un modelo ensemble (RF) para una predicción robusta.

Descripción del aporte del autor

(2 páginas)

El principal aporte de este artículo es el diseño, implementación y validación de un sistema integral de monitoreo de salud mental basado en Big Data para estudiantes de educación superior. Este aporte es tanto metodológico como práctico, ofreciendo un pipeline completo que va desde los datos crudos hasta la identificación de estudiantes en riesgo y recomendaciones educativas.

El problema central que aborda es la detección objetiva, escalable y temprana de problemas de salud mental en una población estudiantil vulnerable, utilizando los rastros digitales que estos dejan naturalmente en su interacción con el ecosistema universitario.

El aporte del estudio se materializa en los siguientes componentes innovadores:

1. **Marco de Integración de Datos Multimodales:** Propone un esquema para unificar **cuatro fuentes de datos comportamentales clave** que suelen estar en silos distintos dentro de una universidad:
 - **Datos de Consumo** (tarjeta universitaria): Para analizar regularidad en las comidas y patrones de gasto.
 - **Datos de Control de Acceso** (dormitorios): Para inferir tiempos de permanencia en la habitación y patrones de sociabilidad (entrar/salir con otros).
 - **Datos de Navegación Web** (logs del campus): Para extraer patrones de uso de internet y posibles contenidos consultados.
 - **Datos de Rendimiento Académico Histórico:** Para incorporar el factor de presión académica (GPA, materias reprobadas).
2. **Metodología Híbrida de Extracción de Características:** Utiliza técnicas avanzadas adaptadas a cada tipo de dato:
 - Para los datos secuenciales de Internet, emplea una Red Neuronal Convolutiva (CNN) para extraer automáticamente características profundas y temporales de las secuencias de URLs visitadas, superando métodos de clasificación manual o basados en n-gramas.
 - Para los datos estructurados (consumo, acceso, notas), aplica métodos estadísticos y de clustering (como el cálculo de entropía para la regularidad de las comidas y K-

Means) para crear características interpretables como "anomalía en horarios de comida" o "tiempo en dormitorio en días de descanso".

3. **Modelo Predictivo y Evaluación:** Entrena y compara varios algoritmos de clasificación (Random Forest, GBDT, Naive Bayes, SVM, Árbol de Decisión) sobre el conjunto de características extraídas. Identifica al Random Forest (RF) como el de mejor rendimiento para esta tarea, logrando una precisión (Precision) del 72% y una exhaustividad (Recall) del 58% en la identificación de estudiantes con problemas de salud mental. El hecho de que el Recall sea la métrica más desafiante y crítica en este contexto subraya la utilidad práctica del sistema.
4. **Análisis de Correlación e Insights Accionables:** Más allá de la predicción, el sistema realiza un **análisis de correlación** para identificar qué características comportamentales están más fuertemente asociadas con los problemas de salud mental. Los hallazgos clave (e.g., correlación positiva con mucho tiempo en el dormitorio en días libres y correlación negativa con el número de pases de acceso) transforman la predicción del modelo en conocimiento concreto para educadores. Esto permite diseñar intervenciones específicas, como fomentar la participación en actividades extracurriculares o monitorear el aislamiento social.

Proceso para obtener el aporte que considera el autor

(1. página)

Para obtener el aporte propuesto, los autores siguieron un proceso de investigación aplicada y de ingeniería de datos rigurosamente estructurado en etapas:

1. **Definición del Problema y Marco:** Se estableció el objetivo de desarrollar un modelo práctico para identificar problemas de salud mental a partir de datos comportamentales disponibles en una universidad.
2. **Adquisición y Preprocesamiento de Datos:**
 - **Recolección:** Se obtuvieron datos anonimizados de 320 estudiantes (80 con problemas de salud mental identificados por el centro psicológico y 240 sanos). Se recopilaron datos de un mes de: consumo en cafetería, registros de acceso a dormitorios, logs de navegación web e historial de calificaciones.
 - **Limpieza e Integración:** Se realizaron operaciones de "join" entre tablas (ej., vincular registro de consumo con ID de estudiante), filtrado de ruido en URLs (eliminar recursos estáticos, direcciones IP), clasificación de URLs en categorías (usando n-gramas) e imputación de valores faltantes en calificaciones usando fórmulas específicas de GPA.
3. **Extracción de Características (Feature Engineering):**
 - **Datos Web (CNN):** Se construyeron series temporales de accesos a Internet por estudiante. Estas secuencias se alimentaron a una CNN personalizada de 5 capas (2 convolucionales, 2 de pooling, 1 fully connected) para extraer automáticamente características abstractas que representen patrones de navegación.
 - **Datos de Consumo:** Se calcularon la frecuencia y la entropía de los horarios de desayuno, almuerzo y cena para medir regularidad. Luego, se usó clustering con K-Means para categorizar a los estudiantes y calcular un puntaje de anomalía (AS) basado en la distancia al centroide y el tamaño del cluster.
 - **Datos de Acceso:** Se derivaron características como Rest_stay_room (tiempo en dormitorio en días libres), Swipe_num (número de pases) y Getup_std (desviación estándar de la hora de levantarse).
 - **Datos de Calificaciones:** Se calcularon el GPA promedio y el número de créditos reprobados.
4. **Modelado y Entrenamiento:**
 - Se construyó un conjunto de características unificado combinando las extraídas por CNN y las calculadas estadísticamente.
 - Se dividió la muestra en conjuntos de entrenamiento, validación y prueba, manteniendo la proporción 1:3 (casos positivos:negativos).
 - Se entrenaron y compararon cinco algoritmos de clasificación: Random Forest (RF),

Gradient Boosting Tree (GBDT), Naive Bayes (NB), Support Vector Machine (SVM) y Decision Tree (DT). Se usaron las métricas Precision, Recall y F1-Measure para la evaluación.

5. **Evaluación, Análisis y Derivación de Conocimiento:**

- Se seleccionó el modelo de Random Forest como el de mejor rendimiento.
- Se evaluó su generalización en el conjunto de prueba, obteniendo las métricas finales (Precision=0.72, Recall=0.58, F1=0.67).
- Se realizó un análisis de correlación para identificar las 20 características más asociadas con los problemas de salud mental, interpretando los resultados para generar recomendaciones prácticas.

Proceso para resolver el problema considerado por el autor

(1. página)

El problema central (monitorear proactivamente la salud mental con datos objetivos) se resolvió mediante la implementación y ejecución del pipeline de datos descrito sobre la muestra real de 320 estudiantes.

La solución se aplicó de la siguiente manera concreta:

1. **Ejecución del Pipeline de Características:** Para cada uno de los 320 estudiantes, el sistema:
 - Procesó sus logs de internet, pasándolos por la CNN previamente entrenada para obtener un vector de características profundas.
 - Calculó sus características estructuradas: regularidad de comidas (entropía, puntaje de anomalía), tiempo en dormitorio en días laborables y libres, número de pases de acceso, GPA, créditos reprobados, etc.
2. **Clasificación con el Modelo RF Optimizado:** El conjunto de características de cada estudiante (CNN features + características estructuradas) se introdujo en el modelo de Random Forest ya entrenado. El modelo, que opera como un ensemble de múltiples árboles de decisión, procesó estas características y emitió una predicción binaria: "con problemas de salud mental" (clase positiva) o "sin problemas" (clase negativa).
3. **Validación de la Solución:** El rendimiento del modelo se midió de forma rigurosa en el conjunto de prueba independiente:
 - De los estudiantes identificados como positivos por el modelo, el 72% realmente tenía problemas (Precision = 0.72). Esto indica una baja tasa de falsas alarmas.
 - El modelo logró identificar correctamente al 58% de todos los estudiantes que SÍ tenían problemas (Recall = 0.58). Esto significa que detectó a más de la mitad de la población en riesgo de manera proactiva.
 - La métrica de equilibrio F1-Measure (0.67) confirmó que el modelo tenía un rendimiento general sólido.

4. **Generación de Perfiles de Riesgo e Insights:** Más allá de la etiqueta "positivo/negativo", el sistema permitió perfilar a los estudiantes en riesgo. El análisis de correlación reveló que los estudiantes con mayores puntuaciones de riesgo tendían a tener:

- Mayor tiempo en el dormitorio en días libres (correlación positiva más fuerte: 0.2719).
- Menor número de pases de acceso (correlación negativa más fuerte: -0.2191), indicando poca movilidad y participación en actividades.
- Patrones de sueño irregulares (alta desviación estándar en la hora de levantarse).

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros) (0.5 página)

Métricas utilizadas:

Los autores emplean las métricas estándar para problemas de clasificación binaria desbalanceada, priorizando adecuadamente la identificación de casos positivos:

- **Precisión (Precision):** Proporción de estudiantes identificados como "con problemas" que realmente los tenían. Importante para no malgastar recursos en falsas alarmas.
- **Exhaustividad (Recall o Sensibilidad):** Proporción de estudiantes que realmente tenían problemas y fueron correctamente identificados. La métrica más crítica en salud mental, donde fallar en detectar un caso (falso negativo) puede tener consecuencias graves.
- **Medida-F1 (F1-Measure):** Media armónica de Precisión y Exhaustividad, que proporciona una puntuación única balanceada.

Resultados obtenidos:

El modelo **Random Forest (RF)** obtuvo los mejores resultados en la comparativa:

- **Precisión (Precision): 0.72 (72%)**
- **Exhaustividad (Recall): 0.58 (58%)**
- **F1-Measure: 0.67**

Comentario sobre la superioridad o relevancia de los resultados:

Los autores comparan directamente el rendimiento de su modelo RF con otros cuatro algoritmos (GBDT, NB, SVM, DT) en la misma tarea y con los mismos datos.

- **RF superó claramente a todos los demás algoritmos en ambas métricas clave.** Por ejemplo, el segundo mejor clasificador en Recall fue GBDT con 0.54, siendo RF un 7% superior. La diferencia es más marcada con el **Árbol de Decisión (DT)**, que tuvo un Recall de solo 0.34, un **20% menos que RF**.
- Si bien no se compara directamente con estudios externos (diferentes datos, definiciones de "caso"), el **Recall del 58%** es un resultado **clínicamente significativo y valioso** en el contexto de un sistema de **cribado o alerta temprana**. Significa que el sistema puede identificar automáticamente a más de la mitad de los estudiantes en riesgo utilizando únicamente sus datos comportamentales pasivos, **sin necesidad de que respondan cuestionarios**. Esto representa una ventaja fundamental sobre los métodos tradicionales basados en encuestas, que dependen de la disposición y autopercepción del estudiante.
- La **Precisión del 72%** indica que, de cada 10 alertas que emita el sistema, aproximadamente 7 serán acertadas. Esta tasa es razonable para un sistema de **priorización**, donde el objetivo no es un diagnóstico clínico, sino señalar a un profesional humano qué estudiantes podrían beneficiarse de una **evaluación o contacto más detallado**. El equilibrio entre Recall (58%) y Precisión (72%), capturado en el F1-Measure de 0.67, sugiere que el modelo es **útil y práctico** para su propósito de monitoreo a gran escala.

Matriz

(0.5 página)

Variable Dependiente

Variable	Dimensiones	Indicadores	Instrumentos
Desarrollo de la salud mental en	Estado psicológico	Nivel de salud mental	Cuestionario psicológico

estudiantes universitarios (Dependiente)			
		Presencia de alteraciones emocionales	Evaluación psicológica
	Evaluación del modelo	Clasificación del estado mental	Algoritmo Random Forest
	Resultado analítico	Nivel de riesgo psicológico	Plataforma Big Data

Variable Independiente

Variable	Dimensiones	Indicadores	Instrumentos
Modelo práctico de educación en salud mental	Estrategias educativas	Talleres, tutorías, actividades prácticas	Guía de observación / Registro institucional
	Metodologías activas	Aprendizaje basado en problemas, casos	Lista de cotejo
	Intervención psicoeducativa	Programas preventivos y formativos	Registro de programas
Uso de big data en educación	Recolección de datos	Datos académicos, conductuales y psicológicos	Sistemas institucionales
	Análisis de datos	Minería de datos, analítica educativa	Software de análisis de datos
	Toma de decisiones	Ajustes de programas basados en datos	Reportes institucionales
Factores académicos	Rendimiento académico	Calificaciones, tasa de aprobación	Registro académico

	Participación estudiantil	Asistencia, interacción en plataformas	Plataforma virtual
	Carga académica	Número de cursos, horas de estudio	Cuestionario estructurado
Factores sociodemográficos	Edad	Años cumplidos	Ficha sociodemográfica
	Sexo	Masculino / Femenino / Otro	Ficha sociodemográfica
	Nivel socioeconómico	Bajo, medio, alto	Cuestionario sociodemográfico
	Tipo de institución	Pública / Privada	Registro institucional

Variable	Dimensiones	Indicadores	Instrumentos
Herramientas de Inteligencia de Negocios	Gestión de datos	Integración de datos	Plataforma Big Data
	Analítica avanzada	Predicción con Random Forest	Algoritmo ML
	Visualización	Reportes analíticos	Dashboard BI