

Plantilla del Estado del Arte

Author (s): Ndikumana, F., Izabayo, J., Kalisa, J., Nemerimana, M., Nyabyenda, E. C., Muzungu, S. H., Komezusenge, I., Uwase, M., Ndagijimana, S., Twiere, C., & Sezibera, V.

Title of paper: Machine learning-based predictive modelling of mental health in Rwandan Youth

Journal: Scientific Reports (Nature)

Volume (issue): Vol. 15

pag – pag (year): 16032 (2025)

Escriba con sus propias palabras

Estado del arte que hace el autor

(1 página)

En la introducción, los autores realizan una revisión del estado del arte sobre la aplicación de técnicas de machine learning (ML) para la predicción de salud mental, con un enfoque particular en jóvenes de Ruanda, un país de bajos ingresos con un contexto post-genocidio único. Comienzan señalando que a nivel mundial, una de cada ocho personas sufre un trastorno de salud mental. Aproximadamente el 75% de la carga global de trastornos mentales y conductuales se concentra en países de ingresos bajos y medios bajos, y entre el 76% y 85% permanecen sin tratamiento. Los trastornos mentales constituyen el 32.4% de los años vividos con discapacidad y el 13% de los años de vida ajustados por discapacidad.

Los autores contextualizan que alrededor del 20% de los niños y adolescentes del mundo tienen una condición de salud mental, siendo el suicidio la segunda causa de muerte entre los jóvenes de 15 a 29 años. En África, la prevalencia de problemas de salud mental parece estar aumentando a medida que la población crece. En Ruanda, estudios recientes muestran que la prevalencia de trastornos mentales en la población general es del 20%, siendo los más comunes el trastorno depresivo mayor (12%), el trastorno de pánico (8.1%) y el trastorno de estrés postraumático (3.1%). Entre los sobrevivientes del genocidio contra los tutsis, la prevalencia alcanza el 53.3%.

Luego, los autores identifican y discuten múltiples líneas de investigación previa en ML aplicado a salud mental:

1. **Aplicaciones generales de ML en salud mental:** Shatte et al. (2019) realizaron una revisión de alcance sobre métodos y aplicaciones de ML en salud mental. Tutun et al. (2023) desarrollaron un sistema de apoyo a decisiones basado en IA para predecir trastornos de salud mental. Tiffin & Paton (2018) discutieron las oportunidades y desafíos de los enfoques de ML en psiquiatría.
2. **Técnicas específicas:** Se ha utilizado procesamiento de lenguaje natural (NLP) para predecir ideación suicida y síntomas psiquiátricos (Cook et al., 2016). Jan et al. (2021) revisaron el papel del ML en el diagnóstico del trastorno bipolar. Samuelson et al. (2022) aplicaron ML para estudiar salud mental y resiliencia durante la pandemia de COVID-19.
3. **Estudios en poblaciones específicas:** Ponce et al. (2022) integraron análisis de sentimiento, algoritmos de ML y datos de redes sociales para desarrollar una aplicación móvil que permite la detección temprana de problemas de salud mental en Perú. Abdul Rahman et al. (2023) emplearon técnicas de ML para predecir el bienestar mental entre estudiantes universitarios utilizando datos de comportamiento de salud.
4. **Predicción en niños:** Sumathi & Poorna (2016) identificaron varios modelos de ML y evaluaron su efectividad para modelar problemas de salud mental en niños, incluyendo TDAH, episodios depresivos mayores, episodios maníacos y ansiedad.

Finalmente, los autores identifican una brecha de conocimiento significativa: el uso de machine learning en la predicción de salud mental en Ruanda es relativamente inexplorado. No hay estudios previos que hayan aplicado ML a datos de salud mental ruandeses a gran escala (n=5,221). Por ello, justifican su estudio como necesario para "aplicar técnicas de machine learning para predecir la salud mental e identificar sus factores de riesgo asociados entre los jóvenes ruandeses".

Motivación del autor (críticas del autor a otros trabajos)

(0.5 página)

La motivación principal del estudio surge de identificar varias limitaciones y brechas en la literatura existente sobre predicción de salud mental con machine learning.

1. **Falta de estudios en contextos de bajos ingresos y post-conflicto:** Los autores critican que la mayoría de los estudios de ML en salud mental se han realizado en países de altos ingresos o en contextos no afectados por conflictos. Ruanda, con su historia de genocidio y alta prevalencia de trastornos mentales (especialmente TEPT), representa un contexto único que no ha sido adecuadamente estudiado con técnicas de ML. Señalan que "el uso de machine learning en la predicción de salud mental en Ruanda es relativamente inexplorado".
2. **Limitaciones en la selección de variables:** Aunque reconocen que su propio estudio se limitó a factores biológicos y sociales (por disponibilidad de datos), los autores implícitamente critican que muchos estudios no consideran el modelo biopsicosocial de manera integral. Factores psicológicos como resiliencia, mecanismos de afrontamiento, autoestima, funcionamiento familiar, estigma, discriminación y ciberacoso no fueron incluidos en estudios previos.
3. **Datos de muestra pequeños:** Muchos estudios previos utilizan muestras pequeñas (menos de 500 participantes), lo que limita la generalización de los hallazgos. El presente estudio utiliza una muestra grande (5,221 participantes), que es significativamente mayor que la mayoría de los estudios previos en la región.
4. **Falta de análisis de comorbilidad:** La mayoría de los estudios se centran en la clasificación binaria (presencia/ausencia de un trastorno), sin abordar la comorbilidad (presencia de múltiples trastornos simultáneamente). Los autores señalan que el 33% de los individuos con trastornos mentales en su muestra tienen dos o más trastornos, lo que hace crucial el análisis de comorbilidad.

Por lo tanto, su motivación es desarrollar modelos de ML que no solo predigan la vulnerabilidad a la salud mental, sino también la comorbilidad, utilizando una muestra grande y representativa de Ruanda, para informar políticas e intervenciones en contextos de bajos ingresos.

Descripción del aporte del autor

(2 páginas)

El principal aporte de este artículo es la aplicación y comparación de cuatro algoritmos de machine learning (Regresión Logística, SVM, Random Forest y Gradient Boosting) para predecir la vulnerabilidad a la salud mental y la comorbilidad de trastornos mentales en jóvenes ruandeses, utilizando una muestra grande (n=5,221) de la Encuesta de Salud Mental de Ruanda (RMHS 2018). Este aporte es novedoso por ser el primer estudio de ML aplicado a salud mental en Ruanda y por su enfoque en la comorbilidad.

El problema central que abordan es la alta prevalencia de trastornos mentales en Ruanda (20% en población general, 53.3% en sobrevivientes del genocidio) y la necesidad de herramientas predictivas que permitan identificar tempranamente a jóvenes en riesgo, especialmente en contextos de bajos ingresos con recursos limitados de salud mental.

El aporte del estudio se materializa en los siguientes componentes clave:

1. **Dataset grande y representativo:** Se utilizaron datos de 5,221 jóvenes (15-24 años) de la Encuesta de Salud Mental de Ruanda 2018, un estudio transversal nacional con muestreo multietápico. Esto representa una muestra significativamente mayor que la mayoría de los estudios previos en ML y salud mental en África.
2. **Marco teórico biopsicosocial:** Los autores fundamentan la selección de variables en el modelo biopsicosocial de George Engel, que considera la interacción compleja de factores biológicos, psicológicos y sociales. Las variables explicativas incluyeron: sexo, edad, estado civil, educación, empleo, pérdida de un ser querido, afiliación a grupos prosociales, experiencia de violencia, religión, condición médica, consumo excesivo de alcohol, experiencia traumática, historial de salud mental personal y familiar.

3. **Comparación rigurosa de cuatro algoritmos:** Se entrenaron y compararon cuatro modelos:
 - **Logistic Regression (LR):** Modelo base lineal para clasificación binaria
 - **Support Vector Machine (SVM):** Con kernel RBF y optimización de hiperparámetros ($C=10$, $\gamma=1$)
 - **Random Forest (RF):** Con $\text{max_depth}=10$, $\text{n_estimators}=200$
 - **Gradient Boosting (GB):** Con $\text{learning_rate}=0.01$, $\text{max_depth}=8$, $\text{n_estimators}=300$
4. **Resultados excepcionales para vulnerabilidad a salud mental:** El modelo Random Forest superó a todos los demás con:
 - Accuracy: 88.8%
 - AUC: 83.59%
 - Precisión, recall y F1-score superiores a los otros modelos
5. **Identificación de factores de riesgo clave:** Mediante análisis de importancia de características (feature importance) del modelo Random Forest, se identificaron los predictores más significativos:
 - Experiencia de eventos traumáticos (mayor importancia relativa)
 - Experiencia de violencia
 - Consumo excesivo de alcohol
 - Antecedentes familiares de trastornos mentales
 - Pérdida de un ser querido
 - Ser mujer y adulto joven (vs. adolescente)
6. **Análisis de comorbilidad (multiclase):** Un aporte distintivo es el análisis de comorbilidad, clasificando a los individuos en tres categorías: un trastorno, dos trastornos, o múltiples (≥ 3) trastornos. El modelo Random Forest alcanzó:
 - Accuracy: 75%
 - AUC: 0.738
 - Precisión: 0.758
 - Recall: 0.750

Los principales predictores de comorbilidad fueron: experiencia traumática, experiencia de violencia, afiliación a grupos prosociales (factor protector), antecedentes familiares de trastornos mentales, pérdida de un ser querido, consumo excesivo de alcohol e historial previo de salud mental.

7. **Validación con datos reales de Ruanda:** A diferencia de estudios que utilizan datos sintéticos o de código abierto sin validación contextual, este estudio utiliza datos reales de una encuesta nacional ruandesa, lo que aumenta la relevancia local de los hallazgos.

Proceso para obtener el aporte que considera el autor

(1. página)

Para obtener el aporte propuesto, los autores siguieron un proceso metodológico sistemático y riguroso, dividido en etapas secuenciales:

1. **Diseño y fuente de datos:** Se utilizó la Encuesta de Salud Mental de Ruanda (RMHS 2018), realizada por el Centro Biomédico de Ruanda en colaboración con instituciones socias. La encuesta fue de tipo transversal, con muestreo multietápico, realizada del 1 al 31 de agosto de 2018. La población objetivo fueron personas de 14 a 65 años. Para este estudio, se extrajo la submuestra de jóvenes (15-24 años según definición de la ONU), obteniendo 5,221 participantes.
2. **Instrumentos de recolección de datos:**
 - **MINI (Mini-International Neuropsychiatric Interview) versión 7.0:** Para determinar la ocurrencia de trastornos mentales comunes (formato de respuesta binaria sí/no). Se evaluaron: episodio depresivo mayor, trastorno de pánico, trastorno obsesivo-compulsivo, TEPT, fobia social, trastorno antisocial de la personalidad, trastorno por consumo de alcohol y sustancias, y conducta suicida.
 - **Evaluación de trauma y consumo de alcohol:** Componente de traumas del MINI, sección I (alcohol) y J (drogas).
 - **Medición de exposición a violencia:** Preguntas específicas sobre experiencias de violencia.
3. **Variables de estudio:**

- **Variable outcome (dependiente):** Cualquier condición de salud mental clasificada según MINI (binario: positivo para al menos un trastorno vs. ninguno). Para comorbilidad: multiclase (1 trastorno, 2 trastornos, ≥ 3 trastornos).
- **Variables explicativas:** 15 variables basadas en el modelo biopsicosocial (ver Tabla 1 del artículo): sexo, edad, estado civil, educación, empleo, pérdida de un ser querido, afiliación a grupo prosocial, experiencia de violencia, religión, condición médica, consumo excesivo de alcohol, experiencia traumática, historial de salud mental personal, antecedentes familiares de trastornos mentales.
- 4. **Preprocesamiento y limpieza de datos:** Se realizó con Python versión 3. Se seleccionaron variables clave basadas en el marco teórico biopsicosocial. Los datos estaban ligeramente desbalanceados (14.48% positivos), por lo que no se aplicaron métodos de balanceo. La selección de características se basó en el método de correlación por filtro. Las variables categóricas se transformaron a formato numérico mediante codificación (dummy variables).
- 5. **División de datos y entrenamiento:** Los datos se dividieron en entrenamiento (70%) y prueba (30%). Se aplicó validación cruzada de 10 pliegues (10-fold cross-validation) durante el entrenamiento. Se verificó sobreajuste y subajuste comparando métricas en entrenamiento y prueba.
- 6. **Optimización de hiperparámetros:** Se utilizó búsqueda en cuadrícula (grid search) para optimizar cada modelo:
 - SVM: C=10, gamma=1, kernel=RBF
 - Regresión Logística: C=0.1, penalty=l2, solver=liblinear
 - Gradient Boosting: learning_rate=0.01, max_depth=8, n_estimators=300, subsample=0.8
 - Random Forest: max_depth=10, min_samples_leaf=1, min_samples_split=2, n_estimators=200
- 7. **Evaluación de modelos:** Se utilizaron métricas: precisión (precision), exhaustividad (recall), F1-score, accuracy y área bajo la curva ROC (AUC). También se generaron matrices de confusión y curvas ROC.
- 8. **Análisis de importancia de características:** Para el mejor modelo (Random Forest), se extrajeron las puntuaciones de importancia de cada característica y se visualizaron en gráficos de barras. También se analizaron las contribuciones de cada característica a la predicción.

Proceso para resolver el problema considerado por el autor

(1. página)

El problema central (predecir la vulnerabilidad a la salud mental y la comorbilidad en jóvenes ruandeses utilizando ML) se resolvió mediante la implementación y validación de los cuatro modelos sobre los datos reales de 5,221 jóvenes de la RMHS 2018.

La solución se aplicó de la siguiente manera concreta:

1. **Preparación del dataset:** Los 5,221 casos se dividieron en entrenamiento (3,655, 70%) y prueba (1,566, 30%). Las variables categóricas se codificaron como dummy variables. No se aplicó balanceo porque el desbalance era leve (14.48% casos positivos).
2. **Entrenamiento de modelos con validación cruzada:** Cada modelo se entrenó utilizando 10-fold cross-validation en el conjunto de entrenamiento:
 - **Logistic Regression:** Se optimizó con C=0.1, penalty=l2
 - **SVM:** Se optimizó con kernel RBF, C=10, gamma=1
 - **Random Forest:** Se optimizó con 200 árboles, profundidad máxima 10
 - **Gradient Boosting:** Se optimizó con 300 estimadores, learning rate 0.01
3. **Evaluación en conjunto de prueba:** Los modelos entrenados se aplicaron al conjunto de prueba (30% de los datos no vistos durante el entrenamiento). Los resultados para vulnerabilidad a salud mental (clasificación binaria) fueron:
 - **Random Forest:** Accuracy 88.8%, AUC 83.59% (mejor modelo)
 - Logistic Regression: Accuracy 88.1%, AUC 82.36%
 - Gradient Boosting: Accuracy 88.1%, AUC 81.92%
 - SVM: Accuracy 87.6%, AUC 81.79%
4. **Análisis de importancia de características (Figura 4):** Utilizando el modelo Random Forest, se identificaron los factores con mayor contribución a la predicción:

- **Experiencia traumática:** Mayor importancia relativa
 - **Experiencia de violencia:** Segundo más importante
 - **Consumo excesivo de alcohol:** Tercero
 - **Antecedentes familiares de trastornos mentales:** Cuarto
 - Ser mujer, adulto joven, pérdida de un ser querido: también significativos
5. **Análisis de comorbilidad (clasificación multiclase):** Se aplicó Random Forest para predecir tres niveles: un trastorno, dos trastornos, múltiples (≥ 3). Resultados:
- Accuracy: 75%
 - AUC: 0.738
 - Precisión: 0.758
 - Recall: 0.750
 - F1-score: 71.1%

La matriz de confusión (Figura 5) mostró un rendimiento sólido, aunque con cierta dificultad para distinguir entre las categorías intermedias.

6. **Identificación de predictores de comorbilidad (Figura 6):** Los factores más influyentes fueron:
- Experiencia traumática
 - Experiencia de violencia
 - Afiliación a grupos prosociales (asociado a menor comorbilidad)
 - Antecedentes familiares de trastornos mentales
 - Pérdida de un ser querido
 - Consumo excesivo de alcohol
 - Historial previo de salud mental
7. **Análisis bivariado complementario (Tabla 3):** Se realizó prueba de chi-cuadrado que confirmó asociaciones significativas ($p < 0.05$) para la mayoría de las variables, excepto afiliación a grupos prosociales ($p = 0.165$). Los porcentajes más altos de trastornos mentales se observaron en: consumo excesivo de alcohol (46.9%), experiencia traumática (44.1%), divorciados/separados (41.2%), y experiencia de violencia (40.8%).

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros) (0.5 página)

Métricas utilizadas:

- **Accuracy (Precisión global):** Proporción total de predicciones correctas $(TP+TN)/(Total)$
- **Precision (Precisión):** Proporción de predicciones positivas que fueron correctas, $TP/(TP+FP)$
- **Recall (Exhaustividad o Sensibilidad):** Proporción de casos reales positivos correctamente identificados, $TP/(TP+FN)$
- **F1-Score:** Media armónica entre precisión y recall, $2(PrecisionRecall)/(Precision+Recall)$
- **AUC (Área bajo la curva ROC):** Mide la capacidad discriminativa del modelo (0.5=aleatorio, 1.0=perfecto)
- **Matriz de confusión:** Tabla que cruza predicciones vs. valores reales

Resultados obtenidos (clasificación binaria - vulnerabilidad a salud mental):

Modelo	Accuracy	AUC	Precision	Recall	F1-Score
Random Forest	88.8%	83.59%	0.888	0.888	0.888
Logistic Regression	88.1%	82.36%	0.881	0.881	0.881

Modelo	Accuracy	AUC	Precision	Recall	F1-Score
Gradient Boosting	88.1%	81.92%	0.881	0.881	0.881
SVM	87.6%	81.79%	0.876	0.876	0.876

Resultados obtenidos (clasificación multiclase - comorbilidad):

- Accuracy: 75%
- AUC: 0.738
- Precision: 0.758
- Recall: 0.750
- F1-score: 71.1%

Comentario sobre la superioridad de los resultados:

El modelo Random Forest supera a los demás en todas las métricas para la clasificación binaria. La diferencia de accuracy entre RF (88.8%) y el segundo mejor (88.1%) es modesta (0.7 puntos porcentuales), pero la diferencia en AUC es más notable: RF supera a LR en 1.23 puntos porcentuales, a GB en 1.67 puntos y a SVM en 1.8 puntos.

En comparación con estudios previos similares mencionados por los autores:

- Rahman et al. (2024) con estudiantes internacionales en UK: RF alcanzó 80% accuracy (8.8 puntos menos)
- Hornstein et al. (2021) en intervención digital para depresión/ansiedad: RF logró alta precisión pero en contexto diferente
- Palacios-Ariza et al. (2023) en trastorno bipolar en Colombia: RF alcanzó 95.1% accuracy (mayor que el presente estudio, pero en un contexto clínico muy específico y muestra más pequeña)

El valor más significativo de este estudio no es solo la precisión del 88.8%, sino:

1. **El tamaño de la muestra (5,221)** es muy grande comparado con la mayoría de estudios de ML en salud mental en África
2. **La aplicación exitosa en un contexto de bajos ingresos y post-conflicto**, donde los recursos de salud mental son extremadamente limitados
3. **El análisis de comorbilidad (75% accuracy)** es un aporte distintivo que pocos estudios abordan
4. **La identificación de factores de riesgo específicos del contexto ruandés** (trauma, violencia) tiene implicaciones directas para políticas públicas

La limitación principal es el F1-score de 71.1% en la clasificación multiclase, que indica dificultades para distinguir entre diferentes niveles de comorbilidad, probablemente debido al desbalance de clases (mayoría con un solo trastorno).

Matriz

(0.5 página)

Variable	Dimensiones	Indicadores	Instrumentos
Variable Dependiente (Outcome)			
Vulnerabilidad a salud mental	Presencia de trastorno mental	Positivo para al menos un trastorno (MINI)	MINI (Mini-International Neuropsychiatric Interview) v7.0
	Ausencia de trastorno mental	Negativo para todos los trastornos	MINI v7.0
Comorbilidad	Un trastorno	1 trastorno mental	MINI v7.0
	Dos trastornos	2 trastornos concurrentes	MINI v7.0
	Múltiples trastornos	≥ 3 trastornos concurrentes	MINI v7.0
Variables Independientes (Explicativas)			
Factores sociodemográficos	Sexo	Femenino, Masculino	Cuestionario estructurado
	Edad	Adolescente (≤ 18), Adulto joven (> 18)	Cuestionario estructurado
	Estado civil	Nunca casado, Casado, Separado/Divorciado	Cuestionario estructurado
	Educación	Sin educación, Primaria, Secundaria/Superior	Cuestionario estructurado
	Empleo	Desempleado, Empleado	Cuestionario estructurado
	Religión	Sin religión/otros, Musulmán, Cristiano	Cuestionario estructurado
Factores biológicos	Condición médica	Sí/No	Cuestionario estructurado

Variable	Dimensiones	Indicadores	Instrumentos
	Consumo excesivo de alcohol	Sí/No	MINI (sección I)
	Antecedentes familiares de trastornos mentales	Sí/No	Cuestionario estructurado
Factores psicosociales	Experiencia traumática	Sí/No	MINI (componente de traumas)
	Experiencia de violencia	Sí/No	Cuestionario estructurado
	Pérdida de un ser querido (lifetime loss)	Sí/No	Cuestionario estructurado
	Afiliación a grupo prosocial	Sí/No	Cuestionario estructurado
	Historial de salud mental personal	Sí/No	Cuestionario estructurado
Variable de Proceso			
Algoritmos de ML	Modelos comparados	Logistic Regression, SVM, Random Forest, Gradient Boosting	Python/scikit-learn
	Hiperparámetros optimizados	Grid search con 10-fold CV	
Variable de Resultado del Modelo			
Predicción (binaria)	Clasificación	Vulnerable a salud mental (sí/no)	Modelo Random Forest (mejor)
Predicción (multiclase)	Clasificación	1, 2, o ≥ 3 trastornos	Modelo Random Forest
Importancia de características	Factores de riesgo	Traumatismo, violencia, alcohol, antecedentes familiares	Feature importance (Random Forest)